

2.【犀牛鸟实战任务】可验证场景：过程评估与错误定位

Hy3 application with process-level evaluation and error localization

【任务描述】

基于 Hy3 构建一个面向可验证场景的 AI 应用，场景领域需存在标准答案，如科学学科、算法竞赛、代码功能等。在此基础上设计一套面向可验证场景的过程评估方法：除判断最终答案的正确性外，还需评估推理过程是否成立、定位错误发生的步骤、归纳错误类型，并识别最终答案正确但推理过程无法支撑该结论的样本。

【完成方式】

参与者从下列方向中选择一个，也可自拟：

- 数学：竞赛题、高等数学、应用题，评估推导链条的完整性与正确性
- 物理：力学、电磁学等计算题，评估建模假设、公式选用、单位与量纲
- 算法竞赛：给定题目与测试数据，评估解法思路、复杂度分析与边界处理
- 代码任务：给定需求与测试用例，评估实现逻辑的正确性，而非仅判断测试是否通过

应用侧

基于 Hy3 构建一个可运行的应用，能够针对该领域的题目/任务产出完整的解答过程，而非仅输出最终答案。

评测题集

构建评测题集，每道题需具备明确的标准答案与可自动校验的判定方式。题目需按难度分层，覆盖从基础到高难度的区间，并说明题目来源、构造方式与分层依据。

过程评估设计

设计一套评估解题过程的方法，至少实现以下能力：

- 过程正确性判定：判断推理链条是否成立，是否存在跳步、循环论证、误用定理、条件遗漏、幻觉等问题
- 错误步骤定位：当解答错误时，定位错误开始出现的步骤
- 错误类型归类：建立错误分类体系，例如题意误读、概念理解错误、计算错误、条件遗漏、跳步推导、格式不符等
- 结果正确但过程不成立的样本识别：例如猜中选项、数值巧合、误用定理却得出正确结果、恰好通过测试用例但实现逻辑存在缺陷等情况

实现方式不限，规则校验、分步 LLM 审查、沙盒执行验证、多 Agent 交叉复核等均可。

过程评估器的有效性验证

需利用标准答案验证所设计的过程评估器是否可靠，至少完成以下两项：

- 定位准确率：在答案错误的样本上，评估器能否判定过程存在问题，并定位到实际出错的步骤

- 误报率：在答案正确的样本上，被评估器判定为过程存在问题的样本，经人工抽检确认其中属于真实问题与属于误报的比例

结果分析

输出完整评测结果，包含最终答案准确率、过程正确率，以及错误类型分布。
按难度分层进行分析，指出模型表现开始明显下降的难度区间。

【产出】

- 开源项目仓库：应用源码、过程评估模块、**README**、环境配置样例与运行说明
- 评测材料：分层题集及标准答案、答案校验脚本、过程评估脚本
- 完整结果：最终答案准确率、过程正确率、错误类型分布、难度分层结果
- 有效性验证结果：定位准确率与误报率的验证数据及人工抽检记录
- 分析报告：过程评估方法设计依据、错误分类体系说明、典型案例分析、模型能力边界与临界点分析
- 时长 2 分钟以内的 **demo** 视频或 GIF，展示一次完整的解题与过程评估流程

【参考链接】

Hy3 仓库：<https://github.com/Tencent-Hunyuan/Hy3>